PEC1: Estadística Descriptiva y Muestreo

UOC

2026-03-06

NOMBRE: Ivan Miranda Moral

Indique claramente el nombre y apellidos en la primera página del informe. Resuelva los ejercicios utilizando R siempre que sea necesario; es importante mostrar cada uno de los pasos realizados para llegar al resultado final. Indique en cada caso qué instrucciones de R ha utilizado y las salidas que se obtienen.

Importante: el informe final se entregará en un archivo con formato "pdf". No se debe entregar el archivo con formato "Rmd" ni se acepatará el informe en ningúnotro formato

Esta PEC debe realizarse de forma estrictamente individual, quedando totalmente prohibido el uso de herramientas de IA. Cualquier indicio de copia será penalizado con un suspenso (D) para todas las partes implicadas y la posible evaluación negativa de la asignatura de forma íntegra.

Recordatorio: Verificación de autoría mediante entrevista de contraste. Esta actividad está sujeta a la verificación de la autoría, la cual puede incluir entrevistas de contraste, tal como se describe en el plan docente de la asignatura. En caso de que el profesorado lo considere necesario, se podrá convocar al estudiante para realizar una entrevista con el objetivo de comprobar la correspondencia entre el contenido presentado y los conocimientos adquiridos, así como la autoría independiente de la actividad. Encontraréis más información en el plan docente de la asignatura.

Introducción

El objetivo de esta PEC es analizar la gestión de residuos en una muestra de municipios. Los datos se encuentran en el archivo *Municipios_Sostenibles.csv*. Este dataset incluye información sobre la población, el tipo de municipio y los principales indicadores de reciclaje.

Variables:

- *Municipio_ID*: Identificador único.
- *Habitantes*: Número de personas residentes.
- *Tipo_Municipio*: Categoría (Urbano, Rural, Turístico).
- *Residuos_kg_capita*: Kilogramos de residuos generados por persona y año.
- *Tasa_Reciclaje*: Porcentaje de recogida selectiva.
- *Coste_Gestion_EUR*: Coste por habitante de la gestión de residuos.
- *Puerta_a_Puerta*: Si el municipio tiene implementado este sistema (Sí/No).

Problema 1

(4 puntos) Importe los datos del archivo *Municipios_Sostenibles.csv* al programa R.

```
sostenibles <- read.csv("Municipios_Sostenibles.csv")
```

Una agencia ambiental quiere evaluar la eficiencia de los municipios.

a) Describa el tipo de cada variable (Nominal, Ordinal, Discreta o Continua). Justifique la respuesta basándose en los apuntes de la asignatura.

```
# Municipio_ID: NOMINAL,
#   aunque los valores son numéricos, no tienen significado numerico ni orden.
# Habitantes: DISCRETA,
#   es una variable cuantitativa que solo se puede tomar con numeros enteros.
# Tipo_Municipio: NOMINAL,
#   clasifica el tipo de municipio pero sin un orden entre ellos.
# Residuos_kg_capita: CONTINUA,
#   es una variable numérica que puede tomar valores reales dentro de un
#   intervalo.
# Tasa_Reciclaje: CONTINUA,
#   es una variable numérica que representa un porcentaje, es decir, valores
#   reales dentro de un rango.
# Coste_Gestion_EUR: CONTINUA,
#   es una variable numéria que puede tomar valores reales.
# Puerta_a_Puerta: NOMINAL,
#   indica si un municipio tiene implementado un sistema puerta a puerta, es una
#   categoria sin orden natural.
```

b) Calcule un resumen numérico completo (media, mediana, cuartiles y desviación típica) de la variable Tasa_Reciclaje. ¿Qué nos indica la diferencia entre la media y la mediana sobre la simetría de los datos?

```
tr_sumario <- sostenibles %>%
                    summarize(min = min(Tasa_Reciclaje),
                          Q1 = quantile(Tasa_Reciclaje, prob = .25),
                          media = mean(Tasa_Reciclaje),
                          mediana = median(Tasa_Reciclaje),
                          Q3 = quantile(Tasa_Reciclaje, prob = .75),
                          max = max(Tasa_Reciclaje),
                          desviacion_tipica = sd(Tasa_Reciclaje))
kable(tr_sumario, caption = "Sumario de Tasa_Reciclaje")
```

Table 1: Sumario de Tasa_Reciclaje

min	Q1	media	mediana	Q3	max	desviacion_tipica
8.5	32	40.006	40.65	48.225	69.9	11.93915

c) Cree una nueva variable denominada Eficiencia_Coste que sea el resultado de dividir la Tasa_Reciclaje entre el Coste_Gestion_EUR. Presente las primeras 5 filas de la nueva variable.

```
Eficiencia_Coste <- data.frame(eficiencia_coste = sostenibles$Tasa_Reciclaje / sostenibles$Coste_Gestio

kable(head(Eficiencia_Coste, n = 5),
      caption = "Eficiencia Coste de las primeras 5 filas")
```

Table 2: Eficiencia Coste de las primeras 5 filas

eficiencia_coste
0.1696648
0.1449938
0.1862832
0.1390449
0.1555714

d) Realice una descripción estadística de la variable cualitativa Tipo_Municipio. Calcule la tabla de frecuencias absolutas y frecuencias relativas, y represente la distribución de los datos mediante un gráfico de sectores. ¿Qué categoría de municipio es la más frecuente en la muestra?

```r
# La tabla de frecuencias muestra la distribución de la variable cualitativa
# nominal Tipo_Municipio, que clasifica los distintos municipios por categorias
# (Rural, Turistico y Urbano) sin un orden predeterminado.
# La categoría más frecuente en el conjunto de datos es "Urbano", ya que
# presenta la mayor frecuencia absoluta y relativa.

frecuencias <- sostenibles %>%
                count(Tipo_Municipio, name = "ni") %>%
                mutate(fi = ni / sum(ni))

kable(frecuencias, caption = "Distribución de Tipo_Municipio")
```

Table 3: Distribución de Tipo_Municipio

Tipo_Municipio	ni	fi
Rural	29	0.29
Turístico	31	0.31
Urbano	40	0.40

```r
setNames(object = frecuencias$fi, c("Rural", "Turístico", "Urbano")) %>%
  pie(col = cm.colors(length(frecuencias$fi)))
labels <- paste(round(frecuencias$ni/sum(frecuencias$ni) * 100, 1), "%")
legend("topright", legend = labels, fill = cm.colors(length(frecuencias$fi)))
```

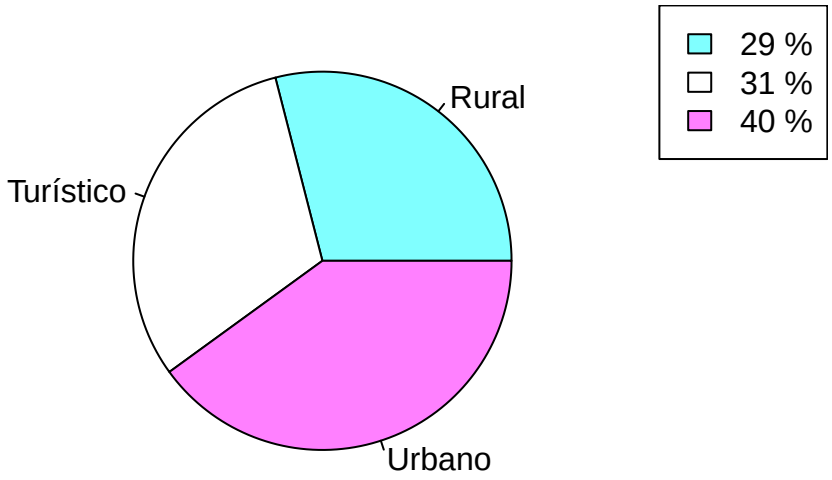

Problema 2

(3 puntos) La agencia sospecha que el sistema de recogida influye en los resultados.

a) Realice un diagrama de cajas (boxplot) de la Tasa_Reciclaje según si el municipio utiliza el sistema Puerta_a_Puerta. Comente las diferencias observadas en la dispersión y en los valores centrales.

```
# El boxplot de Tasa_Reciclaje según Puerta_a_Puerta muestra que los municipios
# sin este sistema presentan una dispersión mayor que los que sí lo usan.
# La mediana también es ligeramente superior en el grupo "No" (41.4 %) respecto
# al grupo "Sí" (39.2 %), aunque la diferencia en los valores centrales
# no es grande.

ggplot(sostenibles, aes(x = Puerta_a_Puerta, y = Tasa_Reciclaje)) +
  stat_boxplot(geom = "errorbar", width = 0.2) +
  geom_boxplot() +
  labs(title = "Tasa_Reciclaje según Puerta_a_Puerta")
```

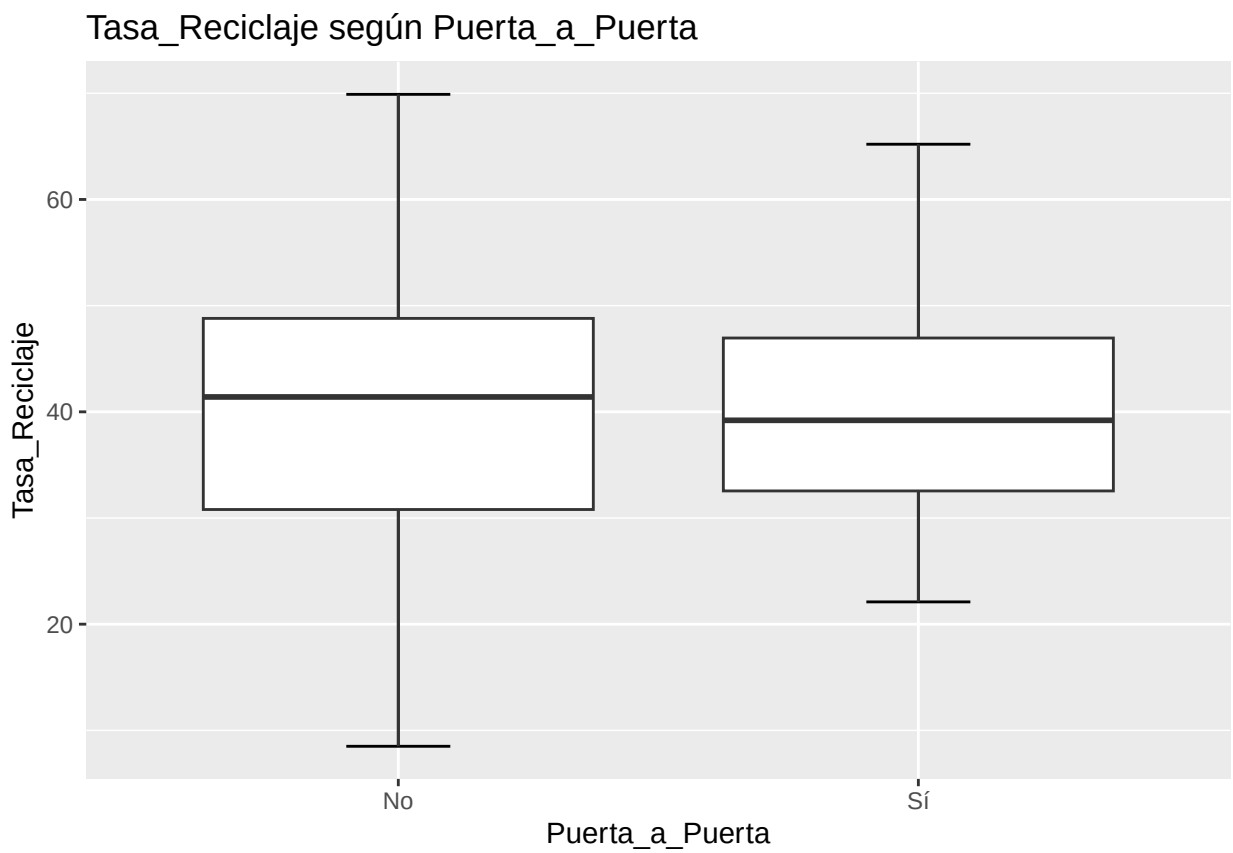

b) Si un municipio presenta una tasa de reciclaje del 90 %, ¿lo consideraría un "outlier"? Razone la respuesta según el concepto de datos atípicos de los apuntes.

```
# SI, una tasa de reciclaje del 90% lo consideraría un "outlier" porque es un
# dato atípico que se sale del limite superior.
# Este caso se contrasta usando la siguiente formula:
#                           Q3 + 1.5 * IQR
# En este caso el limite superior es 72.5625, entonces 90 sería considerado
# un "outlier."

tr_outlier <- sostenibles %>%
        summarize(limite_inferior = quantile(
                      Tasa_Reciclaje, prob = 0.25) - 1.5 * IQR(Tasa_Reciclaje),
                  min = min(Tasa_Reciclaje),
                  Q1 = quantile(Tasa_Reciclaje, prob = 0.25),
                  mediana = median(Tasa_Reciclaje),
                  Q3 = quantile(Tasa_Reciclaje, prob = 0.75),
                  max = max(Tasa_Reciclaje),
                  limite_superior = quantile(
                      Tasa_Reciclaje, prob = 0.75) + 1.5 * IQR(Tasa_Reciclaje),
                  IQR = IQR(Tasa_Reciclaje))

kable(tr_outlier, caption = "Datos tipicos de Tasa_Reciclaje")
```

Table 4: Datos tipicos de Tasa_Reciclaje

limite_inferior	min	Q1	mediana	Q3	max	limite_superior	IQR
7.6625	8.5	32	40.65	48.225	69.9	72.5625	16.225

```
# ADEMÁS,
# en ambos casos de puerta a puerta, una tasa de reciclaje del 90% se
# consideraría un "outlier" porque sale del limite superior.
# Estos limites se ven marcados en el boxplot anterior.

pap_outlier <- sostenibles %>%
        group_by(Puerta_a_Puerta) %>%
        summarize(limite_inferior = quantile(
                      Tasa_Reciclaje, prob = 0.25) - 1.5 * IQR(Tasa_Reciclaje),
                  min = min(Tasa_Reciclaje),
                  Q1 = quantile(Tasa_Reciclaje, prob = 0.25),
                  mediana = median(Tasa_Reciclaje),
                  Q3 = quantile(Tasa_Reciclaje, prob = 0.75),
                  max = max(Tasa_Reciclaje),
                  limite_superior = quantile(
                      Tasa_Reciclaje, prob = 0.75) + 1.5 * IQR(Tasa_Reciclaje),
                  IQR = IQR(Tasa_Reciclaje))

kable(pap_outlier,
      caption = "Datos tipicos de Tasa_Reciclaje según Puerta_a_Puerta")
```

Table 5: Datos tipicos de Tasa_Reciclaje según Puerta_a_Puerta

Puerta_a_Puerta	limite_inferior	min	Q1	mediana	Q3	max	limite_superior	IQR
No	3.80	8.5	30.80	41.4	48.80	69.9	75.80	18.0
Sí	10.95	22.1	32.55	39.2	46.95	65.2	68.55	14.4

Problema 3

(3 puntos) Se quiere realizar una encuesta detallada a 15 municipios para conocer la opinión de la ciudadanía.

a) Explique cómo aplicaría un muestreo estratificado para asegurar que los tres tipos de municipios (Rural, Urbano, Turístico) estén representados proporcionalmente. Cite en qué parte de los apuntes ha encontrado cómo hacerlo.

```
# En este contexto, para llevar acabo un muestreo estratificado seguiría los
# siguientes pasos:
#   1) Dividir la población en estratos en función de la variable Tipo_Muncipio
#       (Rural, Urbano, Turístico) en grupos homogéneos.
#   2) Calcular el peso de cada estrato en la población, es decir, determinar
#       qué proporción de la población total corresponde a cada tipo de
#       municipio.
#   3) Determinar el tamaño de la muestra en cada estrato. Partiendo de la
#       muestra total de 15 municipios, se asigna a cada estrato un número
#       de municipios proporcional a su peso en la población.
```

```r
#   4) Seleccionar aleatoriamente los municipios hasta completar el número
#       asignado a cada estrato.

# Esto se puede implementar en R, de la siguiente manera:

n <- 15
estrat <- frecuencias %>%
            mutate(muestra = round(fi * n))

kable(estrat, caption = "Muestreo estratificado")
```

Table 6: Muestreo estratificado

Tipo_Municipio	ni	fi	muestra
Rural	29	0.29	4
Turístico	31	0.31	5
Urbano	40	0.40	6

```r
muestreo_estratificado <- function(data, filter_cat, cat_type, n) {
    data %>%
      filter(filter_cat == cat_type) %>%
        sample_n(size = n)
}

seis_urbanos <- muestreo_estratificado(sostenibles,
                                       sostenibles$Tipo_Municipio,
                                       "Urbano",
                                       estrat$muestra[3]) %>%
                                          select(Tipo_Municipio, Municipio_ID)

cinco_turisticos <- muestreo_estratificado(sostenibles,
                                       sostenibles$Tipo_Municipio,
                                       "Turístico",
                                       estrat$muestra[2]) %>%
                                          select(Tipo_Municipio, Municipio_ID)

cuatro_rurales <- muestreo_estratificado(sostenibles,
                                       sostenibles$Tipo_Municipio,
                                       "Rural",
                                       estrat$muestra[1]) %>%
                                          select(Tipo_Municipio, Municipio_ID)

kable(rbind(cuatro_rurales, cinco_turisticos, seis_urbanos),
      caption = "Municipios Aleatorizados")
```

Table 7: Municipios Aleatorizados

Tipo_Municipio	Municipio_ID
Rural	155
Rural	127

Tipo_Municipio	Municipio_ID
Rural	105
Rural	185
Turístico	157
Turístico	117
Turístico	113
Turístico	140
Turístico	149
Urbano	104
Urbano	141
Urbano	178
Urbano	166
Urbano	103
Urbano	192

```
#   Referencia: Gil Estallo, A. J. (2019). Muestreo. apartado 5. Muestreo
#       estratificado, pag. 11-13.
```

b) ¿Por qué en este contexto sería mejor un muestreo estratificado que un muestreo aleatorio simple? Justifique la respuesta basándose en la representatividad de la muestra.

```
# El muestreo estratificado garantiza que todos los tipos de municipios estén
# debidamente representados en la muestra. En el caso de utilizar un muestreo
# aleatorio simple, podría pasar que alguna de las categorías de municipios
# estuviese muy poco representada. Por ello, el muestreo estratificado asegura
# la representatividad de la muestra respecto a la estructura real de la
# población.
```