

PEC4: Intervalos de confianza

UOC

NOMBRE I APELLIDOS:

Indique claramente el nombre y apellidos en la primera página del informe. Resuelva los ejercicios utilizando R siempre que sea necesario; es importante mostrar cada uno de los pasos realizados para llegar al resultado final. Indique en cada caso qué instrucciones de R ha utilizado y las salidas que se obtienen.

Importante: el informe final se entregará en un archivo con formato "pdf". No se debe entregar el archivo con formato "Rmd" ni se aceptará el informe en ningún otro formato.

Esta PEC debe realizarse de forma estrictamente individual, quedando totalmente prohibido el uso de herramientas de IA. Cualquier indicio de copia será penalizado con un suspenso (D) para todas las partes implicadas y la posible evaluación negativa de la asignatura de forma íntegra.

Recordatorio: Verificación de autoría mediante entrevista de contraste.

Esta actividad está sujeta a la verificación de la autoría, la cual puede incluir entrevistas de contraste, tal como se describe en el plan docente de la asignatura. En caso de que el profesorado lo considere necesario, se podrá convocar al estudiante para realizar una entrevista con el objetivo de comprobar la correspondencia entre el contenido presentado y los conocimientos adquiridos, así como la autoría independiente de la actividad. Encontraréis más información en el plan docente de la asignatura.

Introducción

La empresa *Cloud-Tech Solutions* ha migrado parte de sus servicios a un nuevo clúster de servidores repartido en dos servidores principales: Srv_A (hardware tradicional) y Srv_B (hardware de última generación). Tras un mes de funcionamiento, el departamento de Operaciones de Red (NOC) ha extraído una muestra aleatoria constituida por un dataset con 1000 registros de telemetría para evaluar si la inversión en el nuevo hardware está justificada y si el sistema cumple con los Acuerdos de Nivel de Servicio (SLA).

Los datos se encuentran en el archivo *Metrics_red.csv*. Este dataset incluye información sobre:

- *id*: Identificador único de la petición.
- *servidor*: Nodo que procesó la solicitud (Srv_A o Srv_B).

- *latencia_ms*: Latencia media global que es el tiempo de ida y vuelta de la señal en milisegundos (ms).
- *uso_cpu*: Porcentaje de carga en el momento de la captura.
- *error_log*: Estado final de la transacción (Exito/Fallo).

Para importar los datos pueden usar las siguientes instrucciones:

```
datos <- read.csv("Metricas_red.csv", header = TRUE, encoding = "UTF-8",
                  stringsAsFactors = TRUE)
datos <- datos[, -1]
```

Problema 1

(1 punto) Para evitar sesgos por inactividad, consideraremos únicamente los registros en los que el *uso_cpu* sea superior al 10%. El filtrado asegura que analizaremos el rendimiento bajo una carga de trabajo real. A este nuevo conjunto de datos le llamaremos *datos_activos*. Y será el conjunto de datos que analizaremos en los problemas 2 y 3. Se pide: cree el conjunto de *datos_activos*, muestre sus 6 primeras líneas y calcule qué porcentaje representa del total de datos.

Problema 2

(1.5 puntos) El SLA exige que la latencia media no supere los 46 ms. Calcule, con la correspondiente instrucción de R, un intervalo de confianza del 95% para la media de la latencia. A partir del resultado obtenido, ¿se cumplen las exigencias del SLA? Indique qué intervalo de confianza se pide, así como qué distribución sigue el valor crítico. Se puede suponer que la latencia se distribuye normalmente.

Problema 3

(2 puntos) Si queremos que el intervalo de confianza del problema anterior tenga un error máximo de 0.2 ms, ¿cuál debería de ser el tamaño del conjunto de *datos_activos*? Explique paso a paso la resolución del problema. Indique también el módulo de teoría, el apartado y las páginas consultadas.

Problema 4

(3.5 puntos) En la mayoría de las arquitecturas, cuando el uso de CPU supera el 70%, el sistema entra en una zona donde el *context switching* (cambio de contexto) y las *colas de espera* empiezan a degradar la latencia de forma no lineal. Se dice que el sistema está bajo *estrés crítico*.

- a) (1 punto) Construya con R una tabla de contingencia de las variables *servidor* y *error_log* cuando el sistema está bajo estrés crítico. Sume por filas y columnas y añada estos totales a la tabla mediante la instrucción *addmargins*.
- b) (1 punto) Utilizando los datos de la tabla de contingencia obtenida en el apartado a), halle con R un intervalo de confianza del 90% de la proporción de fallos en el Servidor A cuando el sistema está bajo estrés crítico. Utilice la función *prop.test* con la opción *correct=FALSE*.
- c) (1 punto) Utilizando los datos de la tabla de contingencia obtenida en el apartado a), halle con R un intervalo de confianza del 90% de la proporción de fallos en el Servidor B cuando el sistema está bajo estrés crítico. Utilice la función *prop.test* con la opción *correct=FALSE*.
- d) (0.5 puntos) En base a los apartados anteriores, ¿podemos decir que las proporciones son diferentes? Razone la respuesta. Compare y comente los intervalos obtenidos.

Problema 5

(2 puntos) En este problema no se va a utilizar el dataframe inicial, sino que se va a simular una variable aleatoria. En relación con los problemas de redes es importante la *Distribución del Tráfico en el Tiempo dentro de un Ciclo (ms)*.

Imaginemos que un servidor divide su tiempo en ciclos de 1 segundo (1000 ms). Las peticiones de los usuarios son totalmente independientes: una persona en Madrid hace clic en un enlace, otra en Barcelona abre una imagen... no están coordinadas entre sí.

En un sistema con tráfico constante y aleatorio, la probabilidad de que una petición llegue entre el milisegundo 12 y el 22, entre el 500 y el 522 o en el 950 y el 972 es exactamente la misma. Así pues, podemos pensar que el tiempo de llegada de una petición sigue una Distribución Uniforme.

Simularemos una población con distribución uniforme, y extraeremos múltiples muestras para analizar su variabilidad.

- a) (0.5 puntos) Genere una población de 10.000 individuos distribuidos según una distribución Uniforme(0, 1000). Es importante fijar la semilla para poder replicar los resultados. Hay que poner: *set.seed(2026)*.
- b) (1 punto) Extraiga 1000 muestras de tamaño 5, 50 y 250 respectivamente. Con las 1000 muestras de tamaño 5 considere la muestra de las medias y lo mismo para las 1000 muestras de tamaño 50 y 250. Por último, calcule la media y la desviación típica de las muestras de las medias de tamaño 5, 50 y 250, respectivamente.
- c) (0.5 puntos) Muestre las tres distribuciones de medias, mediante sus correspondientes histogramas y compárelas. Interprete los resultados y relaciónelos con el Teorema Central del Límite.